

#### 高知工科大学 経済・マネジメント学群

# 計量経済学応用

2. セレクションバイアス

やない ゆうき **矢内 勇生** 



https://yukiyanai.github.io



yanai.yuki@kochi-tech.ac.jp



#### このトピックの目標

- セレクションバイアス (selection bias) を理解する
  - セレクションバイアスが生じるメカニズムを理解する
  - ▶ セレクションバイアスがあると困る理由を理解する
  - ▶ セレクションバイアスのフォーマルな定義を理解する

# 観察データによる 因果推論

単純比較の失敗

## 例:病院は健康にいいか?

- 確認したい因果関係:「病院に行く」→「健康になる」
  - ▶ 原因: 病院に行くこと
  - ▶ 結果: 健康状態
- データを使って確認したい
  - ▶とりあえず、単純に考える
    - 「病院に行った人」と「病院に行かなかった人」の健康状態を比較しよう!

## データを使った単純な比較

「病院に行ったこと(通院)」と「健康状態」の関係

病院に行った?	サンプルサイズ (人数)	健康状態 (1が最悪, 5が最高)	標準誤差
行った	7,774	3.21	0.014
行かなかった	90,049	3.93	0.003

(出典: Angrist and Pischke 2009: p.13)

データからわかる事実: 病院に行かなかった人のほうが健康

5

#### 病院に行くと、健康を害する???

- データによって明らかになったこと: 病院に行かなった人のほうが健康
- 疑問:これは因果関係なのか?
  - ▶「病院に行くと、健康状態は悪化する」と言えるのか?
- 病院が健康に悪い理由を考えてみる: 病院に行くと、
  - ▶ 他の人から病気をうつされる
  - ▶ 病院特有の危険にさらされる(例:X線で被曝する,副作用のある薬を投与される)
  - ▶ 医療ミスの被害者になる
  - ▶ 医療費のせいで食費が減り、栄養失調になる

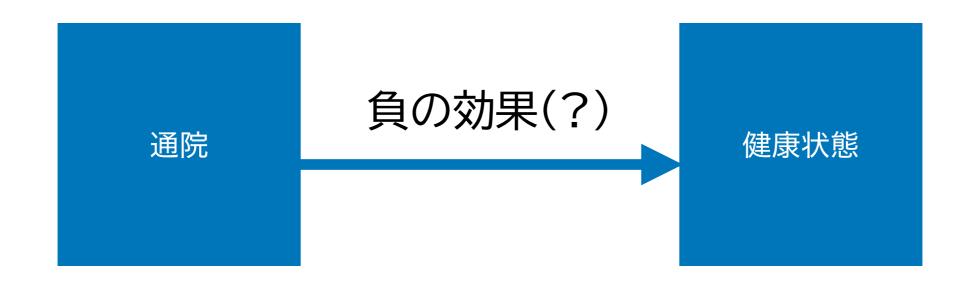
etc.

## 誰が病院に行くか

- 誰(どんな人)が病院に行くかを考えなくていいのか?
  - ▶ 健康な人:そもそも(あまり)病院に行かない!
  - ▶ 病院に行くのは、比較的健康状態が悪い人では?
- 原因である「病院に行くこと」は
  - ▶ 実験のようにランダムに決まっていない
  - ▶ 個人が選べる: セルフセレクション
    - 元の健康状態が悪い人ほど、「病院に行く」を選ぶ
    - 元の健康状態が良い人ほど、「病院に行かない」を選ぶ

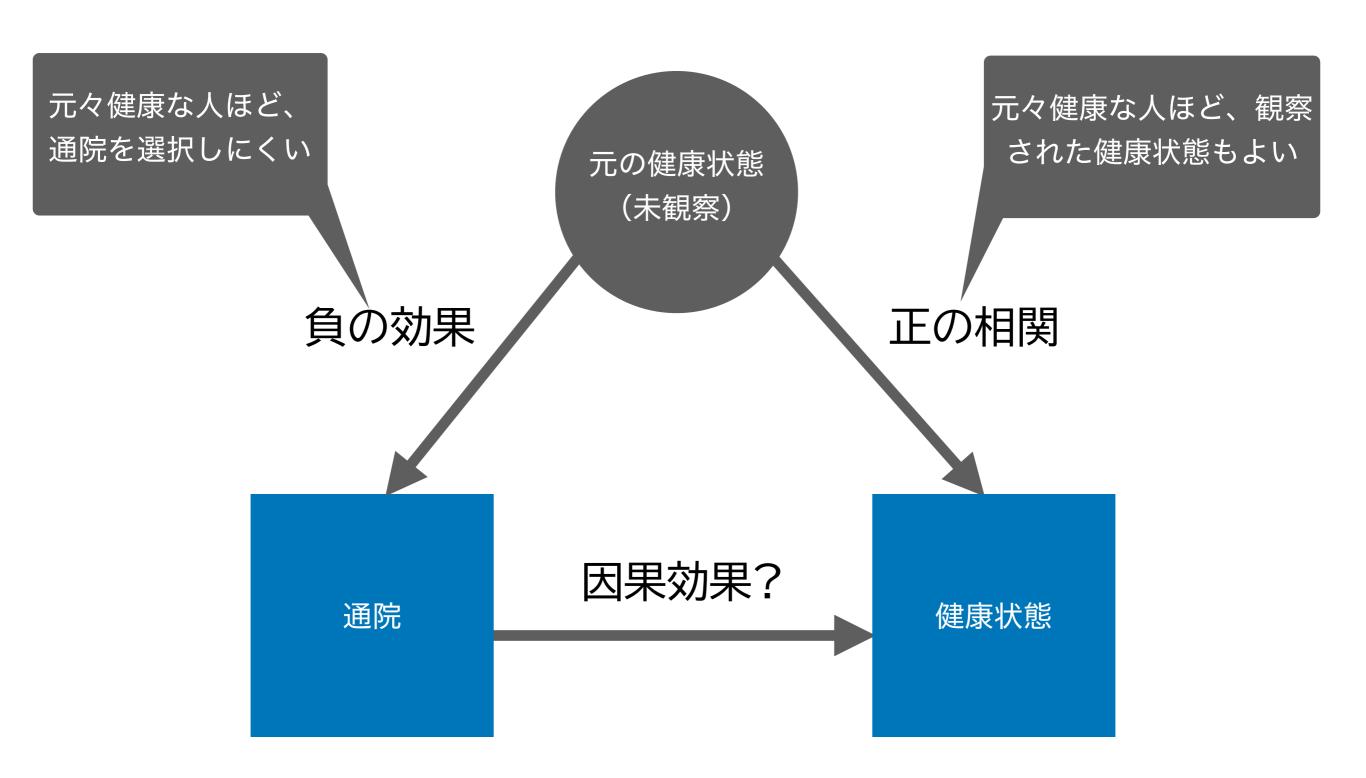
## セルフセレクション(自己選択)

#### 単純な比較



8

#### セルフセレクション(自己選択)



9

©2020 Yuki Yanai

#### 単純比較の差は因果効果ではない!

- 調査・観察データを単純比較しても、因果効果はわからない
  - ▶ 「病院に行った人のほうが不健康である」という事実は、「病院に行くと、不健康になる」という因果関係を意味しない
  - ▶ 理由:セレクションバイアスがあるから!
    - セルフセレクションは、サンプルセレクションの一種(末石 2015 [予習課題] を参照)

## セレクションバイアス (selection bias)

- 因果推論の敵
- 簡単に言うと、原因として考えている変数(処置変数)の値と結果 変数の関係が、想定している因果関係以外に存在する状況
  - フォーマルな定義はもう少し後で
  - ▶ 例: 不健康な人ほど、病院に行きやすい

#### セルフセレクションの例

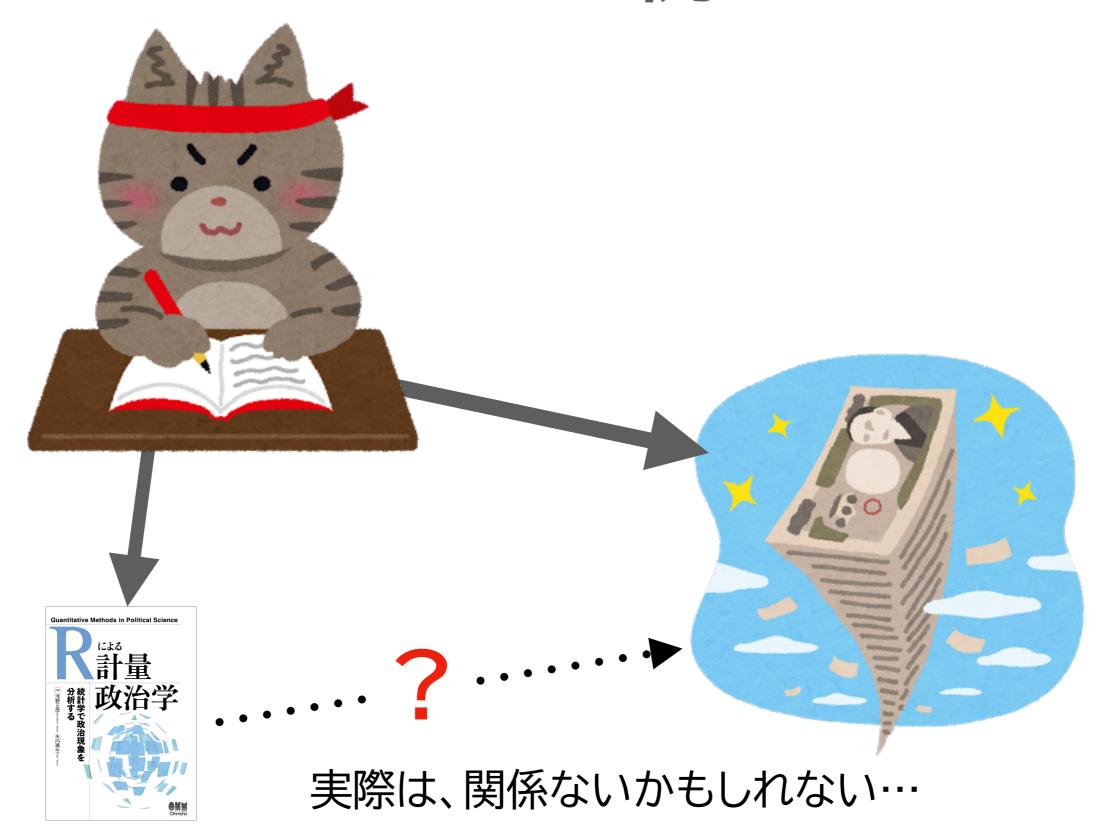
『Rによる計量政治学』を読むと、所得が増える! (私の願望)





12

## セルフセレクションの例



13 ©2020 Yuki Yanai

#### 自己選択以外のセレクションバイアス

- サンプルセレクション
  - ▶単純な例
    - 知りたいこと:日本の大学3年生の統計学の知識
    - 母集団:日本の大学3年生全員
    - サンプル:KUTで「計量経済学応用」を受講している3年生
  - ▶ 教科書第1章の例
    - 処置:ある商品の販促メールを受け取るかどうか
    - 結果:商品を買うかどうか
    - 実施した販促:商品を買ってくれそうな人を選んでメールを送る

## 例:公衆トイレの利用調査

[講義では写真資料を表示]

## 例:公衆トイレの利用調査

[講義では写真資料を表示]

## 潜在的結果アプローチ

Rubin Causal Model

## 記号の準備

- 個人:i = 1,2,...,N
- 処置 (treatment):  $D_i \in \{0,1\}$ 
  - ▶ 処置を受けた(病院に行った): $D_i = 1$
  - ▶ 処置を受けなかった(病院に行かなかった):  $D_i = 0$
- 結果 (outcome):  $Y_i \in \{1,2,3,4,5\}$
- 潜在的結果 (potential outcomes)  $Y_i(D_i) = \begin{cases} Y_i(1) & \text{if} \quad D_i = 1 \\ Y_i(0) & \text{if} \quad D_i = 0 \end{cases}$

#### 教科書との記号の違い

教科書に合わせられず、申し訳ないです。

	教科書 (安井 2020)	授業 (スライド,補助教材)
処置	Z	D
潜在的結果	$Y^{(0)},Y^{(1)}$	Y(0), Y(1)

## 潜在的結果

- 1つの行動に、1つの潜在的結果
- 病院と健康状態の例では:
  - ▶ 可能な行動:「病院に行く」or「病院に行かない」
  - ▶ 潜在的結果
    - 病院に行った場合の健康状態
    - 病院に行かなかった場合の健康状態

#### 処置と潜在的結果

•  $Y_i(D_i)$ : 処置が  $D_i$  の場合の潜在的結果

• 
$$Y_i = Y_i(1)$$
 if  $D_i = 1$ 

• 
$$Y_i = Y_i(0)$$
 if  $D_i = 0$ 

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$$
  
=  $Y_i(0) + [Y_i(1) - Y_i(0)] D_i$ 

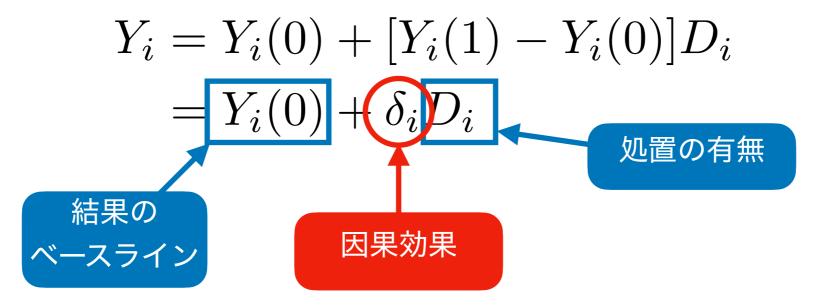
#### 因果効果の定義(Rubinの因果モデル)

ullet 個体 i に関する因果効果(個体処置効果; individual treatment effect: ITE):  $\delta_i$ 

$$\delta_i \equiv Y_i(1) - Y_i(0)$$

#### 因果効果は、潜在的結果の差

▶ 同一個体の同一時点での潜在的結果の差によって定義される



©2020 Yuki Yanai

## 通院と健康状態の例

- $Y_i(1) = Y_i(0) \Leftrightarrow \delta_i = 0$ : 因果効果なし
- $Y_i(1) \neq Y_i(0) \Leftrightarrow \delta_i \neq 0$ : 因果効果あり
  - $> \delta_i > 0$ : 通院が健康状態を改善する
  - $\blacktriangleright$   $\delta_i < 0$ :通院が健康状態を悪化させる
    - 効果  $(\delta_i$  の値)は、潜在的結果のうちどちらを観察するか (観察される処置  $D_i$  の値)によって変わらないはず

#### 疑問

ある個体(個人) i について

 $Y_i(1) \succeq Y_i(0)$ 

を同時に観察できる?

できない!!!!

#### 因果推論の根本問題

(Holland 1986)

## 因果推論の根本問題

表1:処置前

潜在的結果  $Y_i(1)$   $Y_i(0)$  の  $Y_i$ 

表2:処置後

	潜在的結果			
処置	$Y_i(1)$	$Y_i(0)$		
あり $D_i=1$	$Y_i$ として観察される	観察不能		
なし $D_i = 0$	観察不能	$Y_i$ として観察される		

#### 個体の因果効果は観察不可能!

## 複数の個体(集団)を考える

	潜在	的結果	個体レベルの
観察対象	Y(1)	Y(0)	因果効果 $\delta$
1	$Y_{1}(1)$	$Y_{1}(0)$	$Y_1(1) - Y_1(0)$
2	$Y_{2}(1)$	$Y_2(0)$	$Y_2(1) - Y_2(0)$
• •	• •	• •	• •
i	$Y_i(1)$	$Y_i(0)$	$Y_i(1) - Y_i(0)$
• •	• •	• •	• •
N	$Y_N(1)$	$Y_N(0)$	$Y_N(1) - Y_N(0)$

- 個体レベルの因果効果 (ITE) は観察不能
- では、何なら観察できる?

## 集団の平均を考える

• 平均処置効果(平均因果効果; average treatment effect; ATE)

ATE = 
$$\mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$$

- ▶ E[Y(1)]: すべての個体が処置1を受けたときの結果の期待値
- ▶ E[Y(0)]: すべての個体が処置0を受けたときの結果の期待値

## 処置群と統制群

- 処置の値が2種類(0か1)しかないとき
  - ▶ 処置1を受ける:処置を受ける
    - 処置を受けた個体のグループ:処置群、実験群
  - ▶ 処置0を受ける:処置を受けない
    - 処置を受けなかった個体のグループ:統制群、比較群

#### 平均因果効果 (ATE) は観察できる?

- 全個体が処置1を受けたとき: E[Y(1)] は観察(推定)可能
- 全個体が処置0を受けたとき: E[Y(0)] は観察(推定)可能

$$ATE = \mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$$

- 処置1を受けた個体と処置0を受けた個体がいるとき:どちらの 期待値も観察できない
- ATE も観察できない!

#### 観察したいものと観察できるもの

- 観察したいもの:以下の2つを「同時に」観察したい
  - ▶ E[Y(1)]:全個体が処置1を受けたときの結果の期待値
  - ▶ E[Y(0)]:全個体が処置Oを受けたときの結果の期待値
- 観察できるもの
  - ▶ □[Y(1) | D = 1]:実際に処置1を受けた個体が処置1を受けたと きの結果の平均値
  - ▶ E[Y(0) | D = 0]:実際に処置0を受けた個体が処置0を受けたと きの結果の平均値

30

#### 何が計算できるか

#### 観察された平均値の比較

$$\mathbb{E}[Y(1) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]$$

$$= \mathbb{E}[Y(1) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]$$

$$+ (\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 1])$$

$$= \mathbb{E}[Y(1) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 1]$$

$$+ \mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]$$

#### ATT

(average treatment effect on the treated): 処置群に おける平均処置効果

31 ©2020 Yuki Yanai

#### セレクションバイアス

- Selection bias:  $\mathbb{E}[Y(0) \mid D = 1] \mathbb{E}[Y(0) \mid D = 0]$ 
  - ▶  $\mathbb{E}[Y(0) \mid D = 1]$ : 処置を受けた群の個体が、処置を受けなかったときの潜在的結果の期待値
  - ▶  $\mathbb{E}[Y(0) \mid D = 0]$ : 処置を受けなかった群の個体が、処置を受けなかったときの潜在的結果の期待値
- E[Y(0) | D = 1] = E[Y(0) | D = 0] ならセレクションバイアスはない → その場合、
   ATT が推定できる (ATE ではないので注意)
- バイアスがある:処置の値と潜在的結果の値に相関がある
  - ▶ 処置を受けた群と受けていない群で、結果のベースラインに違いがある
    - 例:病院に行った( $D_i = 1$ )人たちのほうが、潜在的な健康状態が悪い( $Y_i(0)$ )の値が小さい)

32 ©2020 Yuki Yanai

#### まとめ

- 調査・観察データの単純比較では、因果効果はわからない
  - ▶ 理由:(多くの場合)セレクションバイアスがあるから
  - ▶ セレクションバイアスの定義:  $\mathbb{E}[Y(0) \mid D = 1] \mathbb{E}[Y(0) \mid D = 0]$
  - セレクションバイアスが起こるメカニズムの例
    - サンプルセレクション:偏ったサンプリング、偏った処置
      - ◆ セルフセレクション(自己選択)
- 次の課題: セレクションバイアスにどう対処する?

33

# 次回予告

Topic 3. RCT