

# 政治学方法論Ⅰ

## 最尤法

矢内 勇生

神戸大学 法学部/法学研究科

2014 年 12 月 10 日

# 今日の内容

## 1 尤度とは？

- 尤度関数 (likelihood function)

## 2 尤度関数の例

- 離散分布の場合 1：二項分布（コイン投げ 1）
- 離散分布の場合 2：ベルヌーイ分布（コイン投げ 2）
- 連続分布の場合：正規分布

## 3 尤度関数の利用

- 尤度比
- 最尤法 (Methods of Maximum Likelihood)

# 尤度関数 (likelihood function)

特定の母数  $\theta$  が与えられたとき、データ  $D$  を得る確率（下の式の右辺）を、 $\theta$  の関数として表現したもの

$$L(\theta|D) = \Pr(D|\theta)$$

→ 与えられた  $D$  に対する、 **$\theta$  の尤もらしさ**を表す！

- ▶  $D$ ：データ
- ▶  $\theta$ ：母数（のベクトル）

定数  $k$  を用いて同値類をまとめて扱う場合もある：

$$l(\theta|D) = k\Pr(D|\theta) \propto \Pr(D|\theta)$$

## 尤度 (likelihood)

尤度関数  $L(\theta|D)$  を、特定の母数  $\theta = \theta_i$  で評価したものを、 $D$  に対する  $\theta_i$  の尤度と呼ぶ

- ▶  $L(\theta_1|D)$  :  $D$  が観測されたとき、母数が  $\theta_1$  であるのはどの程度尤もらしいか
- ▶  $L(\theta_2|D)$  :  $D$  が観測されたとき、母数が  $\theta_2$  であるのはどの程度尤もらしいか

**注意：** 尤度は絶対的な基準ではない！ → モデル内で比較したとき、尤度が大きい方が**より**尤もらしい

# ベイズの公式と尤度

ベイズの公式：

$$\begin{aligned}\Pr(\theta|D) &= \frac{\Pr(D|\theta)\Pr(\theta)}{\Pr(D)} \\ &\propto \Pr(D|\theta)\Pr(\theta) \\ &\propto L(\theta|D)\Pr(\theta)\end{aligned}$$

- ▶  $\Pr(\theta)$ ： $\theta$  の事前確率 ( $D$  を得る前の  $\theta$  に対する信念)
- ▶  $\Pr(\theta|D)$ ： $\theta$  の事後確率 ( $D$  で得た情報を考慮したことにより更新された  $\theta$  に対する信念)

事前/事後確率を受け入れられない → 不確実性の一つの源泉として、尤度を尤度 ( $\neq$  確率) として扱う

## 問題の設定

例題：確率  $\theta$  で表、 $1 - \theta$  で裏が出るコイン

あるコインを 10 回投げたところ、「表」が 8 回出た。このコインを 1 回投げたときに表が出る確率  $\theta$  はいくつか？


- ▶ データ  $D$ ：  $D$  の内容は、
  - ▶ コインを投げた回数：  $n = 10$
  - ▶ 表が出た回数：  $x = 8$
- ▶ 推定したい母数：  $\theta$
- ▶ 検討する尤度：  $L(\theta) = \Pr(D|\theta)$

## 尤度関数の特定

$$\begin{aligned} L(\theta|D) &= \Pr(D|\theta) = \binom{10}{8} \theta^8 (1-\theta)^{10-8} \\ &= 45\theta^8 (1-\theta)^2 \end{aligned}$$

この式が最大になる  $\theta$  を見つける：観察されたデータ  $D$  を生み出すのに最も尤もらしい  $\theta$  を見つける

- ▶  $\theta = 0 \rightarrow L(\theta) = 0$ ：尤もらしくない
- ▶  $\theta = 0.2 \rightarrow L(\theta) = 0.000073$ ：尤もらしい？
- ▶  $\theta = 0.6 \rightarrow L(\theta) = 0.12$ ：尤もらしい？
- ▶  $\theta = 0.8 \rightarrow L(\theta) = 0.30$ ：尤もらしい？
- ▶  $\theta = 0.9 \rightarrow L(\theta) = 0.19$ ：尤もらしい？
- ▶  $\theta = 1 \rightarrow L(\theta) = 0$ ：尤もらしくない

尤度関数  $L(\theta|D)$ 



# 尤度関数の最大化

この例のように単純な尤度関数の最大化は簡単

$$L(\theta|D) = 45\theta^8(1-\theta)^2 = 45(\theta^{10} - 2\theta^9 + \theta^8)$$

最大化条件は、

$$\begin{aligned}\frac{dL(\theta|D)}{d\theta} &= 90(5\theta^9 - 9\theta^8 + 4\theta^7) = 0 \\ &\Leftrightarrow 5\theta^9 - 9\theta^8 + 4\theta^7 = 0 \\ &\Leftrightarrow \theta^7(\theta - 1)(5\theta - 4) = 0 \\ &\Leftrightarrow \theta = \frac{4}{5} \quad (\because \theta \neq 0, 1)\end{aligned}$$

## 問題の設定

例題：確率  $\theta$  で表 (H)、 $1 - \theta$  で裏 (T) が出るコイン

あるコインを 10 回投げたところ、{H, H, T, H, H, H, H, H, H, T} という結果になった。このコインを 1 回投げたときに表が出る確率  $\theta$  はいくつか？

▶ データ  $D$ ：

$$\begin{aligned} D &= \{H, H, T, H, H, H, H, H, H, T\} \\ &= \{1, 1, 0, 1, 1, 1, 1, 1, 1, 0\} \end{aligned}$$

▶ 推定したい母数： $\theta$

▶ 検討する尤度： $L(\theta) = \Pr(D|\theta)$

## 尤度関数の特定 (1)

各ベルヌーイ試行が独立だとすると、

$$L(\theta|D) = \Pr(D|\theta) = \prod_{i=1}^{10} \Pr(D_i|\theta) = \prod_{i=1}^{10} L_i(\theta|D_i)$$

ただし、 $D = \{D_1, D_2, \dots, D_{10}\}$ .

各試行  $i$  について

$$L_i(\theta|D_i) = \Pr(D_i|\theta) = \theta^{D_i}(1 - \theta)^{1-D_i}$$

だから、

$$L(\theta|D) = \prod_{i=1}^{10} [\theta^{D_i}(1 - \theta)^{1-D_i}]$$

## 尤度関数の特定 (2)

$D_i$  の値は 0 か 1 のいずれかであり、

$$L_i(\theta|D_i = 1) = \theta^1(1 - \theta)^0 = \theta,$$

$$L_i(\theta|D_i = 0) = \theta^0(1 - \theta)^1 = 1 - \theta.$$

となるから、結局、

$$L(\theta|D) = \prod_{i=1}^{10} L_i(\theta|D_i) = \theta^8(1 - \theta)^2$$

となる。最大化条件は、

$$\frac{dL(\theta|D)}{d\theta} = 2\theta^7(\theta - 1)(5\theta - 4) = 0$$

$$\therefore \theta = 4/5 \quad (\because \theta \neq 0, 1)$$

## 対数尤度 (log likelihood)

対数をとっても数値の大小関係は変わらない、つまり、 $x_1 < x_2$  ならば  $\log(x_1) < \log(x_2)$  なので、最大値を求めるときは尤度の自然対数をとってもかまわない。自然対数をとると、


$$\begin{aligned}\log[L(\theta|D)] &= \log\left(\prod_{i=1}^{10} [\theta^{D_i} (1-\theta)^{1-D_i}]\right) \\ &= \sum_{i=1}^{10} \log[\theta^{D_i} (1-\theta)^{1-D_i}] = 8\log\theta + 2\log(1-\theta)\end{aligned}$$

最大化条件は、

$$\begin{aligned}\frac{d}{d\theta} \log[L(\theta|D)] &= \frac{8}{\theta} - \frac{2}{1-\theta} = 0 \\ \Leftrightarrow \theta &= \frac{4}{5}\end{aligned}$$

## 離散分布の場合 2: ベルヌーイ分布 (コイン投げ 2)

## 尤度と対数尤度



## 連続分布の場合の問題

$\Pr(X = x|\theta) = 0 \rightarrow$  これを使うと尤度が常に 0 になってしまう

- ▶ 観測値には誤差  $\epsilon$  (精度限界) がある
- ▶ 観測値  $x$  の意味： $x \in (x - \epsilon/2, x + \epsilon/2)$
- ▶ 連続分布の確率密度関数を  $p(x|\theta)$  とすると、 $\epsilon$  が十分小さければ、

$$\begin{aligned} L(\theta|X) &= \Pr[X \in (x - \epsilon/2, x + \epsilon/2)] \\ &= \int_{x-\epsilon/2}^{x+\epsilon/2} p(x|\theta) dx \approx \epsilon p(x|\theta) \end{aligned}$$

- ▶ モデル内で  $\theta$  の比較をするとき、尤度は定数倍してもその有用性が変わらない (同値類は一緒に扱える)  $\rightarrow$  右辺の  $\epsilon$  は無視してかまわない

$\rightarrow$  連続分布の尤度関数は、確率密度関数を使って表す

# 正規分布の例

## 問題の設定

$x_i \sim N(\theta, \sigma^2), i = 1, 2, \dots, n$  で、 $\sigma^2$  を知っているとする。このとき、観察された  $x_i$  に対する  $\theta$  の尤度関数を求める

- ▶  $N(\theta, \sigma^2)$  の確率密度関数：

$$p(x|\theta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{(x - \theta)^2}{2\sigma^2} \right]$$



## 尤度関数の特定

- ▶ 観測値  $x_i$  に対する  $\theta$  の尤度関数は、

$$L_i(\theta|x_i, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{(x_i - \theta)^2}{2\sigma^2} \right]$$

- ▶ 全体の対数尤度は、

$$\begin{aligned} \log L(\theta) &= \log \left[ \prod_{i=1}^n L_i(\theta|x_i, \sigma^2) \right] \\ &= \sum_{i=1}^n \log L_i(\theta|x_i, \sigma^2) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 \end{aligned}$$

## 尤度比 (likelihood ratio)

2つの尤度,  $L(\theta_1|D)$  と  $L(\theta_2|D)$  をどうやって比較する？

- ▶ データ  $x$  に対して、 $x$  に 1 対 1 対応する  $y$  を考えると、

$$\frac{L(\theta_2|y)}{L(\theta_1|y)} = \frac{L(\theta_2|x)}{L(\theta_1|x)}$$

- ▶  $L(\theta_1|D)$  と  $L(\theta_2|D)$  の「比」が重要である（「差」の大きさではなく）
- ▶ → 尤度の絶対的な大きさに意味はない：尤度関数全体を  $k$  倍して考えてかまわない ( $k$  は正の実数)
- ▶ より一般的に、尤度関数  $L$  の代わりに  $f'(\cdot) > 0$  となる  $f(L)$  で置き換えられる：対数尤度を利用する
- ▶ → 尤度関数のうち、母数が含まれていない項は無視できる

## 最尤推定値：Maximum Likelihood Estimate (MLE)

MLE: 尤度関数の最大値 → 最尤法による推論における点推定値

- ▶ MLE は尤度関数の最も簡単な要約
- ▶ MLE は最尤法による推論過程の「一部」を表現しているに過ぎない
- ▶ MLE だけでは尤度関数の特徴を表せない → 尤度関数全体を使って推論を行うべき
- ▶ 対数尤度関数が二次関数で近似できるとき (“regular” likelihood)、尤度関数の特徴を表すには少なくとも2つの数値が必要
  1. 最大値の位置 (location) : MLE
  2. 最大値での曲率 (curvature)

# スコア関数とフィッシャー情報量

- ▶ スコア関数：対数尤度の一次導関数

$$S(\theta) \equiv \frac{\partial}{\partial \theta} \log L(\theta)$$

- ▶ MLE  $\hat{\theta}$  は  $S(\theta) = 0$  の解である
- ▶  $\hat{\theta}$  における曲率を  $I(\hat{\theta})$  とする。ただし、

$$I(\theta) \equiv -\frac{\partial^2}{\partial \theta^2} \log L(\theta)$$

(最大値では二次導関数の値が負なので、マイナスをかけておく)

- ▶  $I(\hat{\theta})$ ：フィッシャー情報量 (observed Fisher information)：この値が大きいほど、 $\theta$  に関する不確実性が低い

# スコア関数とフィッシャー情報量の例 (1-1)

## 正規分布

$x_i \sim N(\theta, \sigma^2), i = 1, 2, \dots, n$  で、 $\sigma^2$  を知っているとする。このとき、観察された  $x_i$  に対する  $\theta$  の MLE とフィッシャー情報量を求める。

- ▶  $\theta$  が含まれていない項は無視できるので、

$$\log L(\theta|x, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2$$

- ▶ スコア関数は、

$$S(\theta) = \frac{\partial}{\partial \theta} \log L(\theta|x, \sigma^2) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \theta)$$

## スコア関数とフィッシャー情報量の例 (1-2)

- ▶ 対数尤度を 2 回微分すると、フィッシャー情報量は、

$$I(\hat{\theta}) = \frac{n}{\sigma^2}$$

- ▶  $\text{Var}(\hat{\theta}) = \sigma^2/n = I^{-1}(\hat{\theta})$  : 情報量が多いほど、推定値の分散が小さい
- ▶  $\text{se}(\hat{\theta}) = \sigma/\sqrt{n} = I^{-1/2}(\hat{\theta})$

# スコア関数とフィッシャー情報量の例 (2-1)

## 二項分布

確率  $\theta$  で成功するベルヌーイ試行を  $n$  回実施した結果、成功が  $x$  回、失敗が  $n - x$  回だった。このとき、観察された  $x$  に対する  $\theta$  の MLE とフィッシャー情報量を求める。

- ▶ 定数項を無視すると、対数尤度は、

$$\log L(\theta) = x \log \theta + (n - x) \log(1 - \theta)$$

- ▶ スコア関数は、

$$S(\theta) = \frac{\partial}{\partial \theta} \log L(\theta) = \frac{x}{\theta} - \frac{n - x}{1 - \theta}$$

- ▶  $S(\theta) = 0$  を解くと、

$$\hat{\theta} = \frac{x}{n}$$

## スコア関数とフィッシャー情報量の例 (2-2)

- ▶ 対数尤度を 2 回微分すると、

$$I(\theta) \equiv -\frac{\partial^2}{\partial \theta^2} \log L(\theta) = \frac{x}{\theta^2} + \frac{n-x}{(1-\theta)^2}$$

- ▶ したがって、フィッシャー情報量は、

$$I(\hat{\theta}) = \frac{n}{\hat{\theta}(1-\hat{\theta})} = \frac{n^3}{x(n-x)}$$



## 尤度区間 (likelihood intervals)

MLE だけでは推定の不確実性が不明 → 「区間推定」が必要

- ▶ 尤度区間を、以下の条件を満たす  $\theta$  の集合として定める

$$\left\{ \theta : \frac{L(\theta)}{L(\hat{\theta})} > c \right\}$$

- ▶  $c \in (0, 1)$  : 任意の閾値
- ▶  $L(\theta)/L(\hat{\theta})$  : 標準化正規化された尤度関数


# 尤度区間の例

確率  $\theta$  で表が出るコインを  $n = 10$  回投げて  $x = 8$  回表がでたときの、 $\theta$  の尤度区間

- ▶  $c = 0.15$  : 尤度区間は  $(0.50, 0.96)$
- ▶  $c = 0.04$  : 尤度区間は  $(0.41, 0.98)$

## 尤度区間の問題

- ▶  $c$  を選ぶ基準がわからない
- ▶ 特定の尤度区間の意味（解釈）がわからない

尤度区間の例：  $n = 10, x = 8$  の二項分布

## 確率に依拠した区間推定：正規分布の場合 (1)

- ▶ 正規分布の場合、先に求めた対数尤度より、

$$\log \frac{L(\theta)}{L(\hat{\theta})} = -\frac{n}{2\sigma^2}(\bar{x} - \theta)^2$$

- ▶  $\bar{x} \sim N(\theta, \sigma^2/n)$  だから、

$$\frac{n}{\sigma^2}(\bar{x} - \theta)^2 \sim \chi_1^2$$

- ▶ つまり、

$$W \equiv 2 \log \frac{L(\hat{\theta})}{L(\theta)} \sim \chi_1^2$$

- ▶  $W$ ：ウィルクス (Wilks) の尤度比統計量

(正規分布以外でも、 $n$  が十分大きければ、 $\chi_1^2$  で近似できる)

## 確率に依拠した区間推定：正規分布の場合 (2)

- ▶ 特定の尤度区間をとる確率を考えると、

$$\begin{aligned}\Pr\left(\frac{L(\theta)}{L(\hat{\theta})} > c\right) &= \Pr\left(2\log\frac{L(\hat{\theta})}{L(\theta)} < -2\log c\right) \\ &= \Pr(\chi_1^2 < -2\log c)\end{aligned}$$

- ▶ ここで、 $0 < \alpha < 1$  によって  $c$  を決める

$$c = \exp\left(-\frac{1}{2}\chi_{1,(1-\alpha)}^2\right)$$

ただし、 $\chi_{1,(1-\alpha)}^2$  は  $\chi_1^2$  の  $100(1 - \alpha)$  パーセンタイル

## 確率に依拠した区間推定：正規分布の場合 (3)

- ▶ このとき、

$$\Pr\left(\frac{L(\theta)}{L(\hat{\theta})} > c\right) = \Pr(\chi_1^2 < \chi_{1,(1-\alpha)}^2) = 1 - \alpha$$

- ▶ これで、 $100(1 - \alpha)$  信頼区間と同等の区間が得られる
- ▶ 特に、 $\alpha = 0.05$  ならば  $c = 0.15$ ,  $\alpha = 0.01$  ならば  $c = 0.04$  である

$c = 0.15$  ( $c = 0.04$ ) の尤度区間は 95% (99%) 信頼区間と同等とみなすことができる

# 尤度比検定

- ▶ 帰無仮説  $H_0: \theta = \theta_0$  を考える
- ▶ 以下の尤度比が「小さ過ぎる」とき、帰無仮説を棄却する

$$\frac{L(\theta_0)}{L(\hat{\theta})}$$

- ▶ 「小さ過ぎる」の基準は？ → 確率的に考える必要
- ▶ ウィルクスの尤度比統計量を使うと、帰無仮説の尤度比が  $c$  のとき、 $p$  値は、

$$p = \Pr(\chi_1^2 > -2 \log c)$$

- ▶ ただし、この式はいつも成り立つわけではない

# 標準誤差

- ▶ 対数尤度が二次関数で近似できるとき、

$$\log \frac{L(\theta)}{L(\hat{\theta})} \approx -\frac{1}{2} I(\hat{\theta}) (\theta - \hat{\theta})^2$$

- ▶ よって、 $\{\theta : L(\theta)/L(\hat{\theta}) > c\}$  となる区間は近似的に

$$\theta \pm \sqrt{-2 \log c} \cdot I(\hat{\theta})^{-1/2}$$

- ▶ 一般的に、MLE  $\hat{\theta}$  の標準誤差は、

$$\text{se}(\hat{\theta}) = I(\hat{\theta})^{-\frac{1}{2}}$$



## ワルド統計量 (Wald statistic)

- ▶ MLE の標準誤差を使うと、Wald 統計量  $z$  は、

$$z = \frac{\hat{\theta} - \theta_0}{\text{se}(\hat{\theta})}$$

- ▶  $|z|$  が大きいほど、帰無仮説  $\theta = \theta_0$  の尤度は小さくなり、 $p$  値も小さくなる
- ▶ 95%ワルド信頼区間は、

$$\hat{\theta} \pm 1.96\text{se}(\hat{\theta})$$

- ▶ ワルド信頼区間の利点： $\hat{\theta}$  に関して左右対称
- ▶ ワルド信頼区間の弱点：対数尤度が二次関数で近似できないと、近似が成り立たない

→ (確率に基づいた) 尤度区間のほうが望ましい場合が多い

## 来週の内容

### 最尤法（続き）

- ▶ 最尤法によるロジスティック回帰
- ▶ プロビット回帰