

統計学 2

10. カイ二乗分布と母分散の推定

矢内 勇生

2018年5月17日

高知工科大学 経済・マネジメント学群

今日の目標

- 不偏分散とは何か理解する
- カイ二乗 (χ^2) 分布とはどんな分布か理解する
- 母分散の推定方法を身につける

分散 (variance)

- 分散：データのばらつき（散らばり具合）を表す統計量
- 0以上の値をとる（データの値がすべて等しいとき0）
- データのばらつきが大きいほど、分散も大きくなる

分散の求め方（復習1）

- ・ 標本分散を表す記号： s^2 （ σ^2 は母分散）

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

標本分散の求め方（復習2）

1. 標本平均を求める
2. 偏差（=観測値 - 標本平均）を各観測値について求める
3. それぞれの偏差を2乗する
4. 偏差の2乗をすべて足して、標本サイズ（ n ）で割る（偏差²の平均値を求める）

標本分散の求め方 (復習3)

- 右のデータの分散を求めてみる

$$\begin{aligned}s^2 &= \frac{16 + 1 + 0 + 4 + 9}{5} \\ &= \frac{30}{5} = 6\end{aligned}$$

	x	偏差	偏差 ²
	1	-4	16
	4	-1	1
	5	0	0
	7	2	4
	8	3	9
計	25	0	30

標本分散の偏り

- 標本をいくつも抽出し、それぞれの標本について標本分散を求める：

標本分散の平均値 $<$ 母分散

➡ 標本分散を母分散の推定に使うと、（小さい方に）偏ってしまう

★ 偏りがない分散の求め方は？

不偏分散 (1)

(unbiased variance)


- 母分散の偏りのない推定値として使える
- 記号： u^2 で表す
- 分散を求める式の名分を少しだけ小さくする

$$u^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2$$


不偏分散 (2)

- 不偏分散：母分散の点推定値
- 標準偏差の点推定値は： u （不偏分散の平方根）
 - ▶ n が十分大きいときは、標本分散で代用してよい
 - ▶ 母平均を知っているときは、標本平均の代わりに母平均を使い、標本分散を求めればよい

標本分散と不偏分散の平均
N(0,1)から各n について1000個の標本を抽出



不偏分散と標本分散の差



χ^2 (カイ二乗) 分布 (chi-squared distribution)


- 確率密度関数 $f(x)$ は、

$$f(x; k) = \frac{\left(\frac{1}{2}\right)^{\frac{k}{2}}}{\Gamma\left(\frac{k}{2}\right)} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} \quad (x > 0 \text{ のとき})$$

$$f(x; k) = 0 \quad (x \leq 0 \text{ のとき})$$

ただし、 k は x の自由度、 $\Gamma(\cdot)$ はガンマ関数。

χ^2 分布



自由度

(degree of freedom: df)

- 自由（独立）に動かせる値の数
- 各統計量に対して自由度が定められる
 - 例：サイズ n の標本の場合
 - ▶ 標本平均の自由度は n
 - ▶ 標本（不偏）分散の自由度は $n-1$

χ^2 分布の定義（ μ が既知のとき）

- Z_1, Z_2, \dots, Z_n を（独立な）標準正規分布に従う確率変数とする

- ただし、
$$z_i = \frac{x_i - \bar{x}}{\sigma}$$

- このとき

$$\chi^2 = z_1^2 + z_2^2 + \dots + z_n^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma^2}$$

は自由度 n のカイ二乗分布に従う

χ^2 分布の定義（ μ が未知のとき）

- Z_1, Z_2, \dots, Z_n を（独立な）標準正規分布に従う確率変数とする

- ただし、
$$z_i = \frac{x_i - \bar{x}}{\sigma}$$

- このとき

$$\chi^2 = z_1^2 + z_2^2 + \dots + z_n^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma^2}$$

は自由度 $n-1$ のカイ二乗分布に従う

χ^2 分布と不偏分散の関係

$$\begin{aligned}\chi^2 &= \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma^2} = \sum_{i=1}^n \frac{n-1}{n-1} \frac{(x_i - \bar{x})^2}{\sigma^2} \\ &= \sum_{i=1}^n \frac{n-1}{\sigma^2} \frac{(x_i - \bar{x})^2}{n-1} = \frac{n-1}{\sigma^2} \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n-1} \\ &= \frac{n-1}{\sigma^2} u^2\end{aligned}$$

* 標本分散を使う場合についても同様に考えられる。

不偏分散 (u^2) の分布

- 母平均を知らないとき、標本サイズ n の標本から求められる不偏分散を u^2 とすると、


$$\frac{n-1}{\sigma^2} u^2$$

は自由度 $n-1$ のカイ二乗分布に従う

χ^2 分布の使い方


χ^2 分布 (カイ二乗分布)

- 自由度 (df) を選ぶ
- 選んだ自由度で、自分が知りたい確率 p (右図の斜線部) を選ぶ
- c を求める: c **以上**の値をとる確率が p



qchisq(p, df) で c を求める

- qchisq(p, df, lower.tail = FALSE)
 - ▶ c の値が得られる
 - ▶ c 以下になる確率を設定するとき
は、lower.tail = TRUE にする



χ^2 分布を利用した推定 (1)

- 自由度は 5 であるとする
- カイ二乗分布の中央部分95%：カイ二乗分布の図で、左右両端から2.5%分ずつ取り除けばよい

- 左端2.5%：

`qchisq(p = 0.025, df = 5, lower.tail = TRUE) → 0.831`

- 右端2.5%：

`qchisq(p = 0.025, df = 5, lower.tail = FALSE) → 12.833`

➡ 自由度5のカイ二乗分布の中央部分95%：[0.831, 12.833]

χ^2 分布を利用した推定 (2)

- $n=6$ のとき（自由度が5のとき）、不偏分散の95%は、

$$0.831 \leq \frac{n-1}{\sigma^2} u^2 \leq 12.833$$

を満たす。

- ➡ 母分散が σ^2 の正規分布から標本サイズ6の標本を抽出するとき、不偏分散の95%については

$$\frac{0.831}{5} \sigma^2 \leq u^2 \leq \frac{12.833}{5} \sigma^2$$

母分散の95%信頼区間

- n と u^2 は知っている（標本から計算できる）
- σ^2 について不等式を解けばよい

$$0.831 \leq \frac{6-1}{\sigma^2} u^2 \leq 12.833$$

$$0.831\sigma^2 \leq 5u^2 \leq 12.833\sigma^2$$

$$\frac{5}{12.833} u^2 \leq \sigma^2 \leq \frac{5}{0.831} u^2$$

一般的な場合

カイ二乗分布：

$$\chi_L^2 \leq \frac{n-1}{\sigma^2} u^2 \leq \chi_U^2$$

信頼区間：

$$\frac{n-1}{\chi_U^2} u^2 \leq \sigma^2 \leq \frac{n-1}{\chi_L^2} u^2$$

今日のまとめ

- 標本分散は偏っているので**不偏分散**を使う
 - n が十分大きければ、標本分散を使ってよい
- カイ二乗分布は自由度によって形が決まる
- 不偏分散（標本分散）を少しだけ変形すると、カイ二乗分布に従う
 - μ が既知：自由度 n のカイ二乗分布
 - μ が未知：**自由度 $n-1$ のカイ二乗分布**